

Brandon Reyes Morales - 22992

Santiago Pereira - 22318

Nacy Gabriela Mazariegos - 22513

Laboratorio 9

Task 1

1. Diferencia Fundamental: Defina con sus propias palabras la diferencia exacta a nivel de píxel entre la Segmentación Semántica y la Segmentación de Instancia.

La segmentación semántica clásica cada píxel de una imagen según su categoría, pero no distingue objetos individuales de la misma clase. Si en una fotografía aparecen 3 personas, todos los píxeles pertenecen a “persona” reciben una etiqueta. El resultado es un mapa por clase, no por objeto individual. U-Net pertenece a esta familia y fue diseñada para producir segmentaciones densas y precisas a nivel de píxel.

La segmentación de distancia también puede trabajar a nivel de píxel, pero además separa cada objeto como una entidad distinta. Si hay 3 personas, no solo marca los píxeles de persona, también genera una máscara diferente para cada una. Mask R-CNN hace esto con R-CNN con una rama extra que predice una máscara por instancia detectada.

2. El Caso U-Net: Explique por qué la arquitectura U-Net (Segmentación Semántica) es ideal y altamente eficiente para la tarea 1 (separar a todos los humanos del fondo), pero explique técnicamente por qué fracasaría si intentamos usarla para la tarea 2 si hay dos réplicas de espadas idénticas cruzadas en la foto.

U-Net puede funcionar para la tarea 1 de la cabina AR el escenario lo importante es lograr una separación precisa entre las personas y el fondo. Ese objetivo corresponde directamente a un problema de segmentación semántica, porque únicamente se requiere decidir, para cada píxel, si pertenece a la clase humano u otra clase. La arquitectura U-Net fue creada para segmentación densa, combinando una ruta de contracción que captura el contexto general de la imagen con una ruta de expansión que recupera información espacial detallada mediante skip connections. Es eficaz para extraer siluetas humanas y sustituir el fondo.

U-Net es muy bueno cuando el propósito es generar una máscara binaria o multicategoría por píxel. En una cabina AR, permite separar a las personas del escenario real y después insertar detrás un fondo artificial. Como el modelo no necesita diferenciar entre “persona

1”, “persona 2” o “persona 3”, sino únicamente resolver la distinción persona vs fondo, el problema se vuelve más directo y también más eficiente a nivel computacional.

U-Net tendría problemas en la tarea 2 si en la imagen aparecen dos réplicas de espadas idénticas cruzadas. El motivo es que U-Net no genera máscaras independientes por objeto, sino que produce una única región asociada a cada clase. Si ambas espadas pertenecen a la clase “espada”, el modelo probablemente marcará todos esos píxeles como una sola masa semántica, sobre todo si ambas están en contacto o presentan oclusión. En esa situación, el sistema no podría determinar con precisión cuál espada corresponde al usuario VIP y cuál pertenece a otra persona de la fotografía.

U-Net contesta puede detectar las espadas pero no puede responder con exactitud cual de las espadas es su dueño. Cuando dos objetos de la misma clase se tocan visualmente, la segmentación semántica no dispone de un mecanismo natural para asignar identidades separadas a nivel de instancia. Por eso, U-Net sería una muy buena solución para remover el fondo, pero no sería suficiente para resaltar de forma selectiva únicamente el arma correcta.

3. El Caso Mask R-CNN: Explique cómo la arquitectura Mask R-CNN (Segmentación de Instancia) resuelve el problema anterior basándose en su naturaleza de "dos etapas" (recordando que hereda de Faster R-CNN). ¿Por qué Mask R-CNN sí podría iluminar una espada de rojo y otra de azul, incluso si se están tocando en la imagen?

Mask R-CNN sí resuelve el problema anterior porque da un enfoque de segmentación de instancia y mantiene la estructura de dos etapas de Faster R-CNN. En una etapa A, el modelo genera regiones candidatas donde posiblemente existan objetos. Después de la etapa B, para cada una de esas regiones, realiza la clasificación, ajusta la bounding box y predice una máscara individual. Esa planificación es basada en propuestas permite que cada objeto tenga su presentación propia, e incluso se detecta cuando tiene objetos cercanos.

La diferencia esencial es que Mask R-CNN no crea un único mapa general para la clase espada, sino una máscara por instancia detectada. Por otro lado Mask R-CNN incorpora una rama paralela dedicada a predecir máscaras de alta calidad para cada instancia, añadiendo poco sobrecosto respecto a Faster R-CNN. Gracias a ello, en una aplicación AR sería posible aplicar efectos visuales distintos a objetos diferentes como por ejemplo iluminar una espada en rojo y otra en azul, incluso si ambas se están tocando, sus máscaras quedan separadas.