

Brandon Reyes Morales - 22992

Santiago Pereira - 22318

Nancy Gabriela Mazariegos - 22513

Laboratorio 9

Task 1

1. Diferencia Fundamental: Defina con sus propias palabras la diferencia exacta a nivel de píxel entre la Segmentación Semántica y la Segmentación de Instancia.

La segmentación semántica clásica cada píxel de una imagen según su categoría, pero no distingue objetos individuales de la misma clase. Si en una fotografía aparecen 3 personas, todos los píxeles pertenecen a “persona” reciben una etiqueta. El resultado es un mapa por clase, no por objeto individual. U-Net pertenece a esta familia y fue diseñada para producir segmentaciones densas y precisas a nivel de píxel.

La segmentación de instancia también puede trabajar a nivel de píxel, pero además separa cada objeto como una entidad distinta. Si hay 3 personas, no solo marca los píxeles de persona, también genera una máscara diferente para cada una. Mask R-CNN hace esto con R-CNN con una rama extra que predice una máscara por instancia detectada.

2. El Caso U-Net: Explique por qué la arquitectura U-Net (Segmentación Semántica) es ideal y altamente eficiente para la tarea 1 (separar a todos los humanos del fondo), pero explique técnicamente por qué fracasaría si intentamos usarla para la tarea 2 si hay dos réplicas de espadas idénticas cruzadas en la foto.

U-Net puede funcionar para la tarea 1 de la cabina AR el escenario lo importante es lograr una separación precisa entre las personas y el fondo. Ese objetivo corresponde directamente a un problema de segmentación semántica, porque únicamente se requiere decidir, para cada píxel, si pertenece a la clase humano u otra clase. La arquitectura U-Net fue creada para segmentación densa, combinando una ruta de contracción que captura el contexto general de la imagen con una ruta de expansión que recupera información espacial detallada mediante skip connections. Es eficaz para extraer siluetas humanas y sustituir el fondo.

U-Net es muy bueno cuando el propósito es generar una máscara binaria o multicategoría por píxel. En una cabina AR, permite separar a las personas del escenario real y después insertar detrás un fondo artificial. Como el modelo no necesita diferenciar entre “persona 1”, “persona 2” o “persona 3”, sino únicamente resolver la distinción persona vs fondo, el problema se vuelve más directo y también más eficiente a nivel computacional.

U-Net tendría problemas en la tarea 2 si en la imagen aparecen dos réplicas de espadas idénticas cruzadas. El motivo es que U-Net no genera máscaras independientes por objeto, sino que produce una única región asociada a cada clase. Si ambas espadas pertenecen a la clase “espada”,

el modelo probablemente marcará todos esos píxeles como una sola masa semántica, sobre todo si ambas están en contacto o presentan oclusión. En esa situación, el sistema no podría determinar con precisión cuál espada corresponde al usuario VIP y cuál pertenece a otra persona de la fotografía.

U-Net contesta puede detectar las espadas pero no puede responder con exactitud cual de las espadas es su dueño. Cuando dos objetos de la misma clase se tocan visualmente, la segmentación semántica no dispone de un mecanismo natural para asignar identidades separadas a nivel de instancia. Por eso, U-Net sería una muy buena solución para remover el fondo, pero no sería suficiente para resaltar de forma selectiva únicamente el arma correcta.

3. El Caso Mask R-CNN: Explique cómo la arquitectura Mask R-CNN (Segmentación de Instancia) resuelve el problema anterior basándose en su naturaleza de "dos etapas" (recordando que hereda de Faster R-CNN). ¿Por qué Mask R-CNN sí podría iluminar una espada de rojo y otra de azul, incluso si se están tocando en la imagen?

Mask R-CNN sí resuelve el problema anterior porque da un enfoque de segmentación de instancia y mantiene la estructura de dos etapas de Faster R-CNN. En una etapa A, el modelo genera regiones candidatas donde posiblemente existan objetos. Después de la etapa B, para cada una de esas regiones, realiza la clasificación, ajusta la bounding box y predice una máscara individual. Esa planificación es basada en propuestas permite que cada objeto tenga su presentación propia, e incluso se detecta cuando tiene objetos cercanos.

La diferencia esencial es que Mask R-CNN no crea un único mapa general para la clase espada, sino una máscara por instancia detectada. Por otro lado Mask R-CNN incorpora una rama paralela dedicada a predecir máscaras de alta calidad para cada instancia, añadiendo poco sobre costo respecto a Faster R-CNN. Gracias a ello, en una aplicación AR sería posible aplicar efectos visuales distintos a objetos diferentes como por ejemplo iluminar una espada en rojo y otra en azul, incluso si ambas se están tocando, sus máscaras quedan separadas.

Task 2

1. Explique matemáticamente, utilizando la fórmula del IoU (Intersección sobre Unión), por qué el algoritmo NMS está causando que los clones superpuestos desaparezcan (Falsos Negativos).

El algoritmo NMS elimina cajas basándose en el IoU (Intersection over Union), definido como:

$$IoU = \frac{Area(B_1 \cap B_2)}{Area(B_1 \cup B_2)}$$

Donde B_1 y B_2 son dos bounding boxes.
En el proceso de NMS:

- Se selecciona la caja con mayor confianza.
- Se eliminan todas las cajas cuyo IoU con esta supere un umbral.

En el escenario planteado, los clones están muy juntos y parcialmente ocluidos, por lo que sus bounding boxes tienen un IoU alto. Matemáticamente, esto implica que:

$$Area(B_1 \cap B_2) \approx Area(B_1 \cup B_2) \Rightarrow IoU \rightarrow 1$$

Debido a esto, NMS interpreta incorrectamente múltiples clones como si fueran el mismo objeto y elimina las cajas superpuestas, generando falsos negativos.

2. **Si usted es el ingeniero a cargo y solo puede modificar los hiperparámetros en el código durante la inferencia: ¿Qué pasaría si ajusta el umbral de IoU del NMS a 0.15? ¿Qué pasaría si lo ajusta a 0.95? Justifique qué valor sería más adecuado para este problema de alta densidad.**

Si se ajusta el umbral de IoU en el algoritmo NMS:

- **IoU = 0.15:**
El NMS se vuelve muy estricto y elimina cajas incluso con poca superposición. Esto provoca la eliminación de muchas detecciones correctas, aumentando los falsos negativos.
- **IoU = 0.95:**
El NMS se vuelve muy permisivo y solo elimina cajas casi idénticas. Esto permite conservar más detecciones, pero genera duplicados (falsos positivos).

Para un escenario de alta densidad y oclusión, es más adecuado utilizar un umbral alto (aproximadamente entre 0.7 y 0.9), ya que reduce la pérdida de detecciones aunque aumente ligeramente la redundancia.

3. **Si el presupuesto le permitiera cambiar el modelo a YOLOv10, explique cómo su arquitectura Asignación Dual de Etiquetas (Dual Label Assignment) resolvería este problema de oclusión sin necesidad de tocar el NMS.**

YOLOv10 introduce un mecanismo de Dual Label Assignment, que combina:

- One-to-many assignment que nos ayuda cuando tenemos múltiples predicciones por objeto (mejor recall)

- One-to-one assignment que es mejor cuando se quiere una predicción precisa (mejor precisión)

En escenas con oclusión:

- Permite que varios bounding boxes representen distintos objetos cercanos.
- Reduce la competencia entre predicciones.
- Mejora la separación entre instancias superpuestas.

Como resultado:

- Las detecciones ya vienen mejor distribuidas.
- El modelo distingue objetos cercanos sin depender tanto de NMS.
- Se reducen los falsos negativos incluso en escenarios densos.